一般社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
IEICE Technical Report
NS2026-123(2026-11)

CAPT における Attention に基づく重要語検出

藤田　捷平†　　山口　実靖††　　陳 キュウ††

†工学院大学 〒163-8677 東京都新宿区西新宿 1-24-2

E-mail: †cm26069@g.kogakuin.jp　††{yamaguchi, chen}sane@cc.kogakuin.ac.jp, chen@cc.kogakuin.ac.jp

あらまし 本研究では,英語非母語話者の発話が「子供っぽい」と認識される問題に着目し,その軽減を目的としたコンピュータ支援発音トレーニング（CAPT）手法を提案する.まず,子供と成人の音声を用いて学習した分類モデルにより,発話の子供っぽさを定量的に評価する.次に,Attention 値を用いて子供っぽさの評価に寄与する単語を特定する.さらに,反実仮想説明に基づき,ピッチの低下,発話速度の上昇,音量の増加を適用し,最も評価値が低下する変更を改善アドバイスとして提示する.評価実験では,提案手法が改善前およびランダムに選択した単語への変更よりも子供っぽさを低減できることを確認した.一方,全単語を変更した場合には,さらに評価値が低下することも示された.

キーワード　Attention, メカニズム, 子供っぽさ, 反実仮想説明, CAPT

1. まえがき

近年,日本人をはじめとする英語非母語話者が,英語を用いてプレゼンテーションやコミュニケーションを行う機会が増加している.非母語話者の中には,自身の英語の発音が「子供っぽい（childish）」と認識されることを懸念する人もおり,子供っぽいと認識されにくい発音の習得を支援することは,重要な研究課題の一つである.また,近年の情報技術や人工知能（Artificial Intelligence: AI）の発展,特に深層学習に基づく音声処理技術や画像処理技術の進歩に伴い,コンピュータ支援言語学習（Computer-Assisted Language Learning : CALL）やコンピュータ支援発音トレーニング（Computer-Assisted Pronunciation Training : CAPT）の研究が進展し,数多くの研究成果が報告されている.

しかし,既存研究の多くは一般的な発音能力の向上を目的としており,著者らの知る限り,「子供っぽさ」という観点から発音改善を支援する研究は,十分に検討されていない.さらに,発音の子供っぽさについて,一般的に受け入れられた定義や定量的な評価手法も確立されていない.

本論文では,深層学習モデルを用いて学習者の音声を解析し,反実仮想説明（Counterfactual Explanation）によって,子供っぽく聞こえにくい発音を実現するための改善アドバイスを生成する手法を提案する.

提案システムでは,まず,子供の音声と成熟した音声を識別する教師あり分類モデルを用いて入力音声を評価し,Attention（注意機構）の重みに基づいて,子供っぽいと判断されることに強く寄与する領域を特定する.次に,特定された領域に対して,音の高さの低下の変更を加え,反実仮想音声を生成する.生成された各反実仮想音声を再評価し,子供っぽさの評価値が最も低くなる変更方法を特定する.そして,その変更内容を発音改善のためのアドバイスとして学習者に提示する.さらに,提案手法の有効性を検証するため,著者の一人を被験者とした評価実験を実施する.

本論文の主な貢献は,以下の 3 点である.

1. 子供っぽさの定量的評価手法の提案

教師あり学習モデルを用いて子供の音声と成熟した音声を分類することにより,「子供っぽさ」という抽象的な概念を定量的に評価するための枠組みを提案する.

2. Attention を用いた子供っぽさに寄与する領域の特定手法の提案

Attention の重みを利用することで,入力音声の中から,子供っぽいと判断されることに寄与する領域を特定する手法を提案する.

3. 反実仮想説明を用いた具体的な発音改善アドバイスの生成手法の提案と有効性の検証

反実仮想説明を用いて,子供っぽさを軽減するための具体的な改善アドバイスを生成する手法を提案する.さらに,著者の一人を被験者とした評価実験を通じて,その有効性を検証する.

2. 関連研究

2.1. 英語プレゼンテーション練習支援

Tagami らは,深層学習を用いた英語プレゼンテーション練習支援システムを提案している[1].このシステ

This article is a technical report without peer review, and its polished and/or extended version may be published elsewhere.
Copyright ©2026 by IEICE

ムは,練習者の英語音声を解析し,目標とする発話方法へ近づくための助言を出力するものである.練習者の音声を解析して改善点を提示するという点で,本研究と共通している.

一方,Tagami らの研究は,主に英単語の強勢に基づく発音練習を対象としており,発話の大人っぽさや子供っぽさを改善するための支援を目的としたものではない.本研究では,深層学習モデルが算出した子供度と Attention 値を利用し,子供っぽく聞こえない英語発話の習得を支援する点に特徴がある.

2.2. Attention 機構

Vaswani らは,再帰型ニューラルネットワークや畳み込みニューラルネットワークを使用せず,Attention 機構を中心として構成された Transformer を提案した[2].Attention は,モデルが入力データのどの部分に注目して推論したかを表す重みとして解釈できる.

本研究では,音声分類モデルによって得られた単語ごとの Attention 値を,モデルが子供音声と判断した根拠を推定するために使用する.Attention 値の高い語を練習者に提示することで,発話全体ではなく,モデルの判断に強く影響した箇所を重点的に練習できるシステムを目指す.

2.3. 非母語話者の外国語アクセント英語における年齢推定

Jiao らは,英語を第二言語として話す非母語話者の外国語アクセント音声を対象として,話者の母語や音響的特徴が知覚年齢に与える影響を調査した.実験では,アラビア語,韓国語および中国語を母語とする話者が英語の文章を読み上げ,その音声を同じ三つの言語背景を持つ聞き手に提示して,話者の年齢を推定させた.

実験の結果,中国語母語話者はアラビア語母語話者よりも若く評価される傾向が確認された.また,話者と聞き手の母語が同じ場合など,言語的な親近性が高い条件では,話者の年齢をより正確に推定できることが示された.さらに,平均基本周波数(F0)と発話速度が知覚年齢の有意な予測要因となった.この結果は,音声から知覚される年齢が,加齢に伴う生理的な変化だけでなく,母語に依存する発話方法や社会文化的特徴からも影響を受けることを示している.

同研究と本研究は,非母語話者による英語音声の年齢印象と,基本周波数や発話速度などの音響的特徴との関係を扱う点で共通している.一方,Jiao らの研究は人間の聞き手による実年齢の推定を目的としている.これに対して本研究では,大人と子供の英語音声を学習した分類モデルによって child probability を算出し,その値を低下させるための発話練習支援を行う.また,Attention を用いて重点的に練習する単語を提示し,声の高さ,発話速度および音量の変化が child probability に与える影響を検証する点に特徴がある.

2.4. 母語話者および非母語話者による外国語アクセント音声の年齢推定

Gnevsheva らは,英語母語話者および日本語母語話者が発話した英語音声を用いて,話者の母語と聞き手の言語的な親近性が年齢推定に与える影響を調査した.実験では,英語母語話者と日本語母語話者による英語音声を,英語母語および日本語母語の聞き手に提示し,各話者の年齢を推定させた.

実験の結果,実年齢と推定年齢の相関は,英語母語の聞き手が英語母語話者の音声を聞いた条件で最も高かった.一方,英語母語の聞き手が日本語アクセントを持つ英語音声を聞いた条件では,年齢推定の相関が最も低かった.また,英語母語の聞き手は,日本語母語話者を英語母語話者よりも若く評価する傾向を示した.さらに,男性話者と平均基本周波数の低い話者は,より高い年齢として評価される傾向が確認された.以上から,外国語アクセント音声の年齢推定には,基本周波数などの音響的特徴に加え,聞き手の言語経験やアクセントへの親近性が関係することが示された.

同研究は,日本語母語話者の英語音声が英語母語話者よりも若く知覚される可能性を示しており,日本人英語学習者の子供っぽい発話を対象とする本研究の背景として重要である.一方,同研究は,人間の聞き手が話者の年齢を推定する知覚実験であり,発話を改善するための支援方法は扱っていない.本研究では,深層学習によって入力音声の child probability を算出するとともに,単語ごとの Attention を利用して練習箇所を提示する.そして,提示された単語の発話方法を変化させることで,子供っぽくない英語発話の習得を支援する.

2.5. アクセント変調を用いた第二言語英語学習者の発音誤り検出・診断

Jiang らは,第二言語として英語を学ぶ話者を対象とした発音誤り検出・診断において,学習者のアクセントの違いに対して頑健な End-to-End 型モデルを提案した.従来の発音誤り検出モデルでは,学習者の母語によって異なる多様なアクセントがモデルの性能を低下させることが課題となっていた.

そこで Jiang らは,アクセントの特徴を発音誤り検

出・診断モデルへ組み込み,音響特徴を話者のアクセントに応じて変調する accent-aware module を導入した.これにより,モデルがアクセントの違いを考慮しながら,正しい発音と誤った発音を識別できるようにした.第二言語英語学習者の音声を収録した L2-ARCTIC データセットを用いた実験の結果,提案モデルは従来の End-to-End 型モデルや発音評価手法と比較して,発音誤り検出・診断性能を向上させた.

同研究と本研究は,非母語話者の英語音声を深層学習を用いて解析し,英語学習者の発話改善を支援する点で共通している.一方,Jiang らの研究は,音素単位の発音が正しいか,または誤っているかを検出・診断することを目的としており,発話が大人っぽく,または子供っぽく知覚されるかは対象としていない.本研究では,発音の正誤ではなく,大人音声と子供音声を学習した分類モデルによって child probability を算出する.さらに,WhisperX で取得した単語区間と HuBERT の Attention を対応付け,Attention 値の高い語を練習箇所として提示する.練習後の音声を分類モデルへ再入力し,発話方法の変更によって child probability が低下するかを評価する点が異なる.

3. 提案手法

本稿では,発話練習者の音声を解析し,深層学習モデルが子供っぽいと判断した根拠を練習者に提示し,練習者が指摘点を改善することにより子供っぽくない発話を実現する手法を提案する.

子供っぽい音声の定義:本研究では,こどもの発話音声と,大人の発話音声を学習して判断モデルを作成し,そのモデルが「子供の音声である」と推論した音声は子供っぽい音声であるとみなす.

提案システムでは,最初に大人と子供の英語音声を用いて教師あり学習を行い,入力された音声が大人の音声であるか,子供の音声であるかを推論する分類モデルを構築する.

練習者が英語発話音声を入力すると,分類モデルは子供音声である確率,すなわち child probability を出力する.モデルが入力音声を子供音声と判定した場合は,単語ごとの Attention 値を算出する.そして,Attention 値の高い語をモデルの判断根拠とみなし,重点的に練習すべき箇所として練習者へ提示する.

改善のための助言として,Attention 値の高い語の声の高さを低くする「低音化」の条件を設定する.この助言をもとに練習者が練習する.

図 1 に,提案システムにおける音声解析の処理フローを示す.入力音声はモノラル化および 16 kHz へのリサンプリングを行った後,HuBERT による音声分類経路と WhisperX による単語認識経路の二つに入力する.

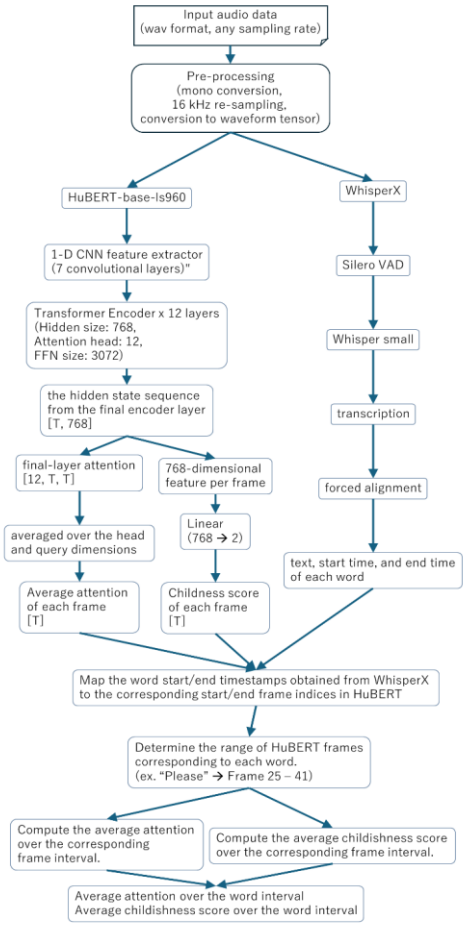


図 1：WhisperX による単語境界推定と HuBERT による単語単位分析の処理フロー

HuBERT による音声分類経路では,事前学習済みモデル HuBERT-base-ls960 を使用する.入力波形から 1 次元 CNN 特徴抽出器および 12 層の Transformer Encoder を通して,各時間フレームに対応する 768 次元の特徴ベクトルを取得する.この特徴系列を時間方向に平均した後,768 次元から 2 次元へ変換する全結合層に入力し,大人音声と子供音声の分類スコアを算出する.さらに Softmax 関数を適用し,入力音声が子供音声に属する確率を child probability として出力する.

WhisperX による単語認識経路では,Silero VAD を用いて入力音声中の発話区間を検出し,Whisper small によって英語音声を文字起こしする.その後,強制アライメントを行い,認識された各単語の文字列,開始時刻および終了時刻を取得する.したがって,本システムでは HuBERT が単語を認識するのではなく,WhisperX が認識した単語とその時間情報を用いて HuBERT の出力を単語単位に分割する.

WhisperX が出力した単語の開始時刻および終了時刻は,HuBERT の開始フレーム番号および終了フレー

ム番号へ変換する.これにより,各単語が HuBERT のどの時間フレームに対応するかを決定する.例えば,WhisperX が認識した「Please」の時間区間が HuBERT の第 25 フレームから第 41 フレームに対応する場合,この範囲を「Please」に対応するフレーム区間とする.

Attention の算出には,HuBERT の最終 Transformer 層から得られる Attention を使用する.最終層の Attention は,Attention head から query までの値 1 について平均し,HuBERT の各時間フレームに対して一つの平均 Attention を算出する.次に,各単語に対応するフレーム区間に含まれる平均 Attention をさらに時間方向に平均し,その結果を単語ごとの Attention 値とする.この値は,HuBERT 内部で各フレームが平均的にどの程度参照されたかを表す指標として用いる.

また,HuBERT の各フレームに対応する 768 次元特徴ベクトルを学習済み分類層へ入力し,各フレームの Child クラススコアを算出する.単語に対応するフレーム区間の Child クラススコアを平均することで,単語ごとの平均 Child クラススコアを求める.ただし,分類器は本来,音声全体を時間平均した特徴量を用いて学習されているため,この値は厳密なフレーム単位の子供確率ではなく,各単語区間が Child クラスに示す局所的な傾向を表す補助的なスコアとして扱う.

以上の処理により,WhisperX が認識した各単語について,開始時刻,終了時刻,対応する HuBERT フレーム区間,平均 Attention 値および平均 Child クラススコアを取得する.本発表では,単語ごとの平均 Attention 値を比較し,値が高い単語をモデル内部で強く参照された語として抽出する.そして,その語を重点的に練習すべき候補として練習者へ提示する.

4. 性能評価

4.1 評価方法

Attention 値の高い語を変化させる提案手法と,同じ変化を音声内のランダムに選んだ語に適用する手法を比較する.これにより,Attention を用いて練習箇所を限定することが,子供度の低下に有効であるかを検証する.

表 1 に実験に使用した音声データの情報を示す.大人の訓練データには Common Voice[6]に収録された 20～30 代の音声 200 件,子供の訓練データには Hugging Face[7]で公開されている子供音声 200 件を使用した.また,検証用データとして,訓練データに使用されていない大人と Hugging Face に収録されていた English children[8]と記載されている子供の音声をそれぞれ 100 件使用した.テストデータには「People look, but no one ever finds it.」「Please call me stella.」という英文を使用した.被験者は A, B, C, D の 4 人であり，被験者 A, B は著者であり，C, D は著者ではない.

表 1 .使用した音声データ

使用音声	個数
Common voice(adult):訓練データ	200
Hugging face(child):訓練データ	200
Common voice(adult):検証データ	100
English children(child):検証データ	100
練習者の音声データ:テストデータ	100
提案システムから指摘された部分を重点的に練習:テストデータ	30
ランダムに指定された部分を重点的に練習	30

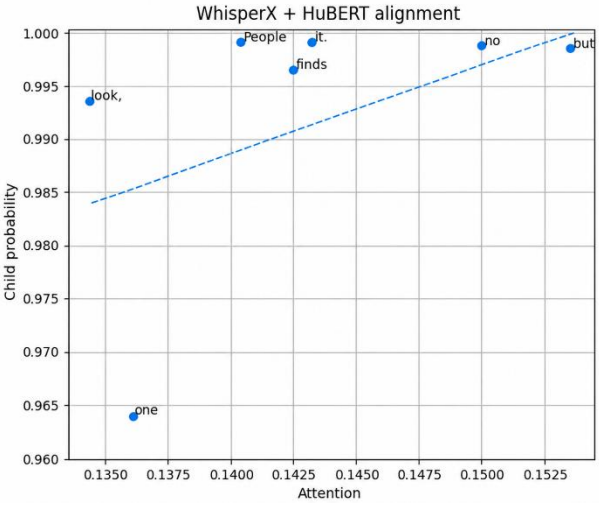


図 2 .練習前音声の Attention と子供度の値
「People look, but no one ever finds it.」

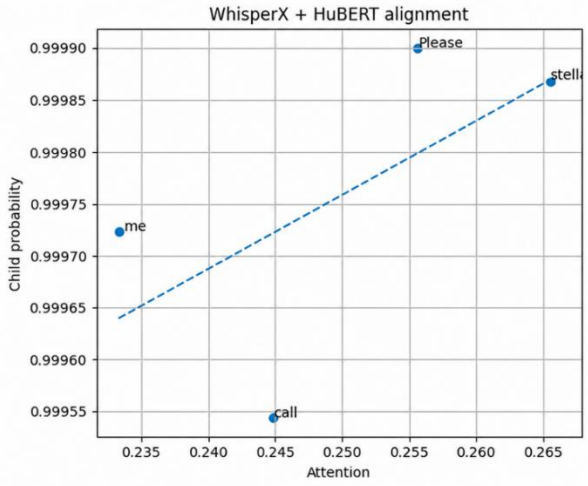


図 3 .練習前音声の Attention と子供度の値
「Please call me stella.」

提案手法では,被験者の練習前の音声を提案システムに入力し,システムから子供っぽいと判断される原因となる語が「重点的に練習すべき語」として出力され,各被験者は自身が得た語を重点的に練習する.被験

者 A の練習前音声の Attention と子供度の値の関係を図 2,3 に示す.被験者 A は,図 2 より Attention 値の高かった「but」「no」「it」と,図 3 より「Please」「call」「Stella」を重点的に練習した.

また,それに対して提案手法を用いない条件に関してはランダムに選択した 3 個の単語を重点的に練習する様に指示した.具体的には全被験者に対して「People look, but no one ever finds it.」に対しては「People」「ever」「finds」を,「Please call me stella.」に対しては「Please」「me」「stella」を重点的に練習するように指示した.

各被験者には,提案手法によって選択された 3 単語,またはランダムに選択された 3 単語について,声の高さを低くすることを意識して英文を発話するよう指示した.各条件で 30 回の録音を行い,Child Probability の平均値,最大値および最小値を算出した.各条件について,子供度の平均値,最大値,最小値を算出した.

4.2 評価結果

図 4,図 5,表 2 に,各話者の練習前,提案手法を用いた練習後,ランダム手法を用いた練習後の音声の Child Probability の平均値と各手法の差を示す.

「People look, but no one ever finds it.」の文では,4 名すべてで提案手法の平均値が練習前およびランダム手法を下回った(子供っぽくない判定となった).特に被験者 A で練習前からの低下幅が大きく,被験者 C でも低下が確認された.一方,被験者 D と被験者 B では低下幅が比較的小さかった.ランダム手法では,練習前より値が低下した話者と,ほぼ同程度またはやや高い値を示した話者が見られた.これは音声の低音化しても,対象がランダムな語であれば効果がないことを示している.

「Please call me Stella.」では,被験者 A と被験者 C で提案手法の平均値が練習前およびランダム手法を下回った.被験者 B でも低下したが,その幅は小さかった.被験者 D では,提案手法と練習前の平均値は図上ほぼ同程度であり,明確な低下は読み取れなかった.提案手法は各話者でランダム手法より低い平均値を示した.

両英文を比較すると,被験者 A と被験者 C では両英文で提案手法による低下が確認された.一方,被験者 D の低下幅は小さく,特に「Please call me Stella.」では変化がほとんど見られなかった.この結果は,提案手法の効果が話者および発話内容によって異なることを示している.被験者 B では大きな違いが確認されなかった.

「People look, but no one ever finds it.」では,4 名すべてで提案手法による小さくない低下が確認されたが,その低下幅には話者間で差が見られた.

一方,「Please call me Stella.」では,被験者 A,被験者 C で比較的大きな低下が確認されたのに対し,被験者 B,被験者 D では小さな低下にとどまった.これらの結果から,提案手法による Child Probability の低下幅は,話者および発話内容によって異なることが分かる.

表 2: 練習前と各手法の平均 Child Probability の差

被験者	People		Stella	
	提案	ランダム	提案	ランダム
A	0.06000	0.02900	0.06870	0.04940
B	0.00450	−0.00162	0.00264	−0.00121
C	0.01997	0.00692	0.05440	0.00322
D	0.00846	0.00014	0.00001	−0.00180

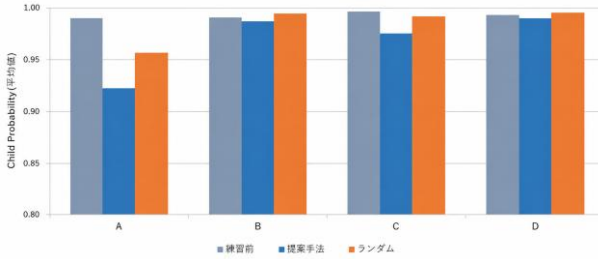


図 4. 「People look, but no one ever finds it.」の判定結果

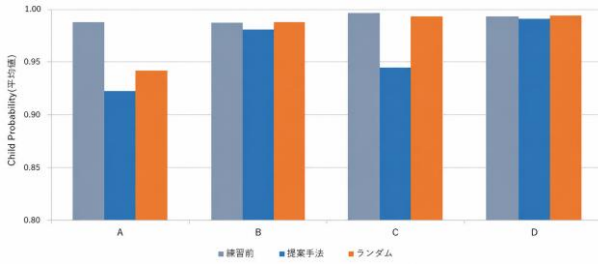


図 5. 「Please call me stella.」の判定結果

5. 考察

本実験では,両英文の各話者において,提案手法の Child Probability の平均値がランダム手法を下回った.この結果は,同じ数の単語に低音化を指示する場合,Attention に基づく単語選択が,今回の分類モデルの評価値を低下させるうえで有効である可能性を示す.ただし,この結果だけから,Attention 値の高い単語が子供っぽさの直接的な原因であるとは結論できない.

一方,改善幅には話者間の差が見られた.被験者 A と被験者 C では両英文で低下したが,被験者 D では低下幅が小さかった.指定された単語の低音化の程度や,対象外の単語の発話方法,発話速度および音量の変化が結果に影響した可能性がある.実際の練習音声では,指定された単語以外の音響特性も変化し得るため,基本

周波数などを測定し,指示がどの程度実行されたかを確認する必要がある.

「Please call me Stella.」における被験者 A では,提案手法が「Please」「call」「Stella」,ランダム手法が「Please」「me」「Stella」を対象とし,3 単語中 2 単語が共通していた.したがって,両条件の違いは主に「call」と「me」の選択に限られ,変更箇所の類似性が条件間の差を小さくした可能性がある.4 単語からそれぞれ 3 単語を選ぶ場合,最低 2 単語が必ず重複するため,この制約は短い英文に 3 単語の練習を適用したことに由来する.一方,「People look, but no one ever finds it.」では,全ての被験者で両手法の対象単語に重複はなかった.

ただし,対象単語の重複は,提案手法とランダム手法の差が小さくなる可能性を説明するものであり,練習前から Child Probability が低下しにくいことを直接説明するものではない.また,「Please call me Stella.」でも被験者 C には比較的大きな条件間の差が見られるため,重複だけで結果を説明することはできない.単語ごとの音響変化や発話時間の違いも併せて検討する必要がある.

評価指標の解釈には限界がある.Child Probability は子供音声と成人音声の分類に基づくモデルの出力であり,その低下が人間の聞き手にとっての子供っぽさの軽減を意味するとは限らない.本実験の値は全体として高い範囲にあり,提案手法によって値が低下しても,成人音声としての判定に変わったことを示す結果ではない.今後は,聞き手による子供っぽさと発話の自然さの評価を行い,モデル出力との対応を確認する必要がある.

各条件の複数の録音は同一話者による反復であり,録音数を独立した話者数として扱うことはできない.話者数と英文数を増やすとともに,ランダムな単語選択を複数回行い,練習順序や反復による影響を考慮した評価が必要である.短い英文では対象単語の重複を避けにくいため,英文の長さと選択単語数を変え,重複率と改善幅の関係を調べることも今後の課題となる.

次に,発話が子供っぽいと感じられる要因について考察する.子供っぽさは声の高さだけでなく,発話速度,抑揚,リズム,語彙の選択など,複数の要因によって形成されると考えられる.しかし,本研究ではこれらの特徴が分類結果に与える影響を個別に検証できていない.今後は,基本周波数や発話速度などの音響的特徴と子供っぽさの関係を定量的に分析するとともに,語彙などの言語的特徴についても検討し,子供っぽさを生じさせる要因の解明を今後の課題とする.

6. おわりに

本研究では,英語非母語話者の発話における子供っぽさの軽減を目的として,HuBERT の Attention を用いた重要語検出に基づく CAPT 手法を提案した.評価実験では,Attention 値の高い単語を重点的に練習することで,ランダムに選択した単語を練習する場合よりも Child Probability が低下する傾向を確認した.一方,改善幅には話者間で差が見られ,短い英文では選択単語の重複が比較に影響する可能性が示された.今後は,被験者数および評価英文数を増やすとともに,人間の聞き手による主観評価を実施し,提案手法の有効性をさらに検証する.

文　献

[1] Tagami, Y., Kojima, T., Yamaguchi, S.: Computer-assisted English presentation learning system based on word stress in pronunciation. In: 2024 IEEE 48th Annual Computers, Software, and Applications Conference (COMPSAC), pp. 1721–1725. IEEE, Osaka(2024).https://doi.org/10.1109/COMPSAC61105.2024.00271

[2] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is all you need. In: Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000–6010.Curran Associates Inc., Red Hook (2017).

[3] Jiao, D., Watson, V., Wong, S.G.-J., Gnevsheva, K., Nixon, J.S.: Age estimation in foreign-accented speech by non-native speakers of English. Speech Communication106,118–126(2019). https://doi.org/10.1016/j.specom.2018.12.005

[4] Gnevsheva, K., Bürkle, D.M.: Age estimation in foreign-accented speech by native and non-native speakers. Language and Speech 63(1), 166–183 (2020). https://doi.org/10.1177/0023830919827621

[5] Jiang, S.-W.F., Yan, B.-C., Lo, T.-H., Chao, F.-A., Chen, B.: Towards robust mispronunciation detection and diagnosis for L2 English learners with accent-modulating methods. In: 2021 IEEE Automatic Speech Recognition and Understanding Workshop (ASRU), pp. 1065–1070. IEEE, Cartagena (2021). https://doi.org/10.1109/ASRU51503.2021.9688291

[6] Mozilla Foundation: Common Voice. Mozilla Common Voice. https://commonvoice.mozilla.org/en (accessed 15 October 2026).

[7] Zhang, J., Zhang, Z., Wang, Y., Yan, Z., Song, Q., Huang, Y., Li, K., Povey, D., Wang, Y.: speechocean762: An open-source non-native English speech corpus for pronunciation assessment. In: Proc. Interspeech2021(2021).https://doi.org/10.21437/Interspeech.2021-1252

[8] jsun39: KidSpeak-Instruct. Hugging Face Datasets. https://huggingface.co/datasets/jsun39/KidSpeak-Instruct (accessed 15 October 2026).